UC: Sistemas Inteligentes
Curso: Informática

25/26

UNIVERSIDADE
DA MAIA **UMAIA**

Previsão de Gorjetas

NYC Yellow Taxi



Felipe Castilho – a047152
Juliana Moreira – a047188
Marta Vieira – a046756

Introdução

Desenvolvemos um sistema inteligente que permite:
- Analisar um conjunto de dados
- Construir modelos preditivos
- Aplicar e comparar técnicas de Machine Learning e Deep Learning

Queremos prever (targets):
- Se vai haver gorjeta [tip_given, **tip_high**] – Classificação (sim/não; alta/baixa)
- O valor da gorjeta [**tip_amount**] – Regressão

O trabalho está dividido em fases:
- 1 – Tratamento de Dados
- 2 – Modelos Clássicos (RF, LR, SVM, J48, MLP, NB Gaussiano)
- 3 – Redes Neuronais
- 4 – Comparação de Modelos

Vamos mostrar os resultados principais.



Descrição do Dataset utilizado

Variável	Descrição
VendorID	Identificador da empresa de táxi
Tpep_pickup_datetime	Hora/data de recolha do passageiro
Tpep_dropoff_datetime	Hora/data de desembarque do passageiro
Passenger_count	Número de passageiros
Trip_distance	Distância da viagem
RatecodeID	Código do tipo de tarifa
Store_and_fwd_flag	Indicador de transferência de dados ('Y' = Sim, 'N' = Não)
Payment_type	Tipo de pagamento (1 = Cartão, 2 = Dinheiro, 3 = Sem cobrança, 4 = Contestação)
Fare_amount	Tarifa base
Tip_amount	Gorjeta

Tratamento de dados

Os pagamentos em dinheiro **não registam gorjeta** eletrónica.

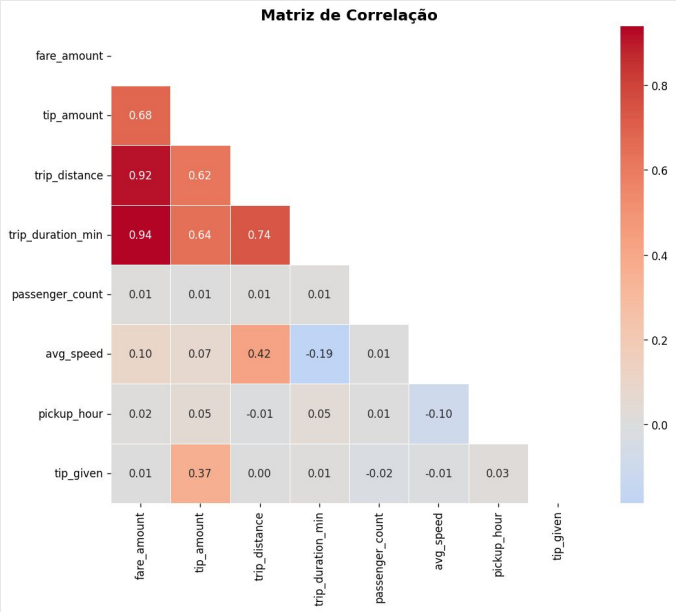
Incluir estas viagens com **tip_given = 0** introduziria **ruído** sistemático nos targets.
Assim, o dataset foi **filtrado** para incluir apenas viagens com pagamento por cartão.
Consequência: desequilíbrio de classes em **tip_given** (96,5% positivos) reflete a realidade dos pagamentos por cartão.
Por isso, o **target principal** de modelação é **tip_high**: gorjeta acima do percentil 75 nas **viagens com gorjeta** registada (tip_amount ≥ P75 ≈ $2,45).



No **tratamento de dados**:

- Removemos **linhas incompletas** e **mal formadas** no parsing.
- Aplicamos **IQR** nas variáveis principais – tarifa, gorjeta, distância e duração.
- Aplicamos **regras de domínio** (**tip_amount** maior que 0, **payment_type** não null, **fare_amount** entre 0 e 300 dól., **trip_duration** entre 30s e 180 minutos, …)

Matriz de Correlação



A matriz de correlação confirma que **o valor da gorjeta**, **a distância da viagem** e **o tempo da viagem** são as features mais correlacionadas com **o valor da tarifa**.

Existe **correlação positiva** clara entre **o preço da viagem (tarifa)** e o **valor da gorjeta**:

- Quanto maior a tarifa, maior a gorjeta esperada.

A **distância** e a **duração** da viagem também se correlacionam **positivamente** com a gorjeta, mas com maior **dispersão**, sugerindo que **outros fatores** como o contexto, hora... também influenciam.

Treino e Otimização de Modelos

O dataset foi dividido em três subconjuntos, **60 / 20 / 20**:

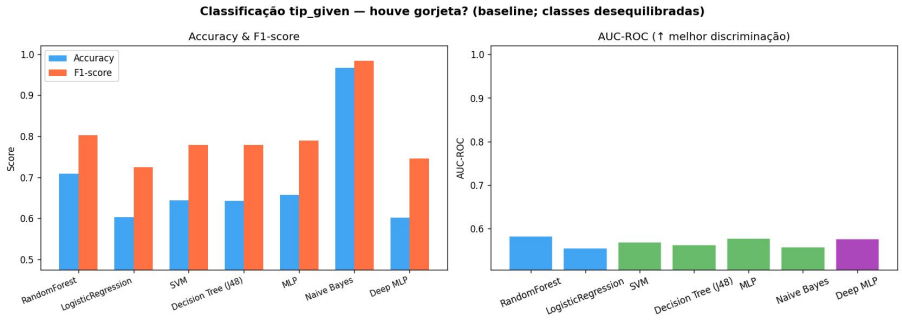
- **60% de treino** garante uma quantidade de dados suficientes para treino.
- **20% de validação**, volume suficiente para que a variância da estimativa de PR-AUC (qualidade das previsões) seja baixa.
- **20% de teste**, dados que o modelo nunca viu durante o treino.

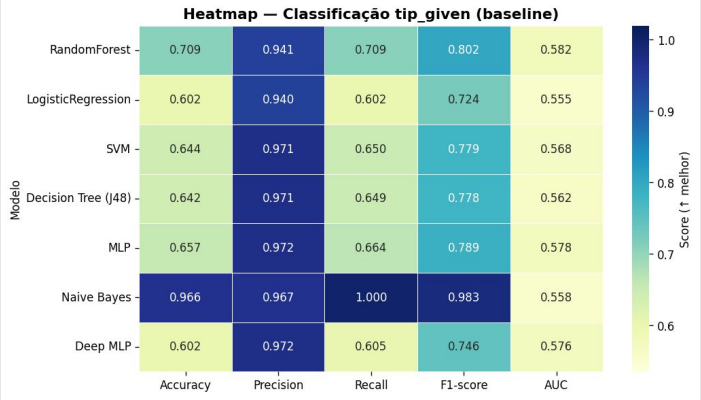
Treinámos **6** classificadores (modelos) por cada **target.** Todos os modelos usam as **mesmas features.**

- **Spark ML**:
  - Random Forest
  - Logistic Regression
- **scikit-learn**:
  - SVM
  - Árvore de Decisão J48,
  - MLP
  - Naive Bayes Gaussiano;

Comparação - tip_given

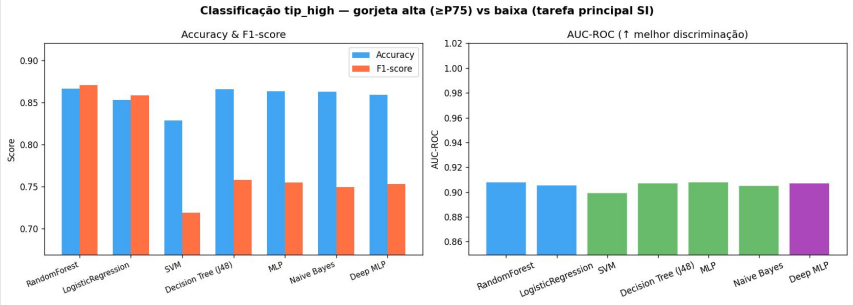
Os gráficos abaixo comparam o desempenho de todos os modelos na tarefa de classificação nominal ***tip_given***, considerando métricas de **Accuracy, F1-score, AUC-ROC e a matriz de scores** completa.

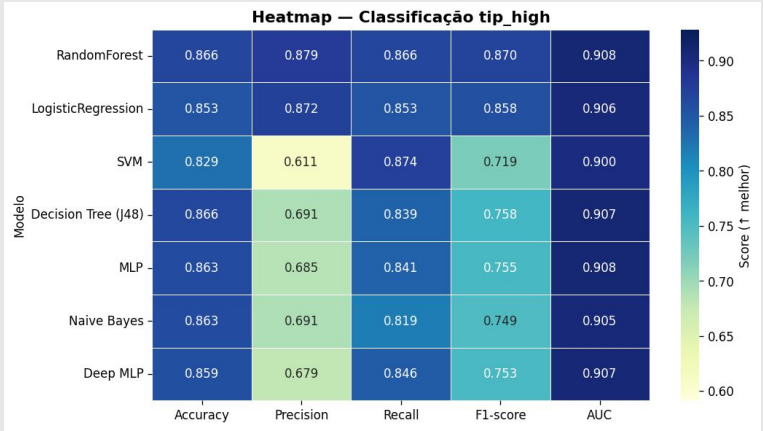




Comparação - tip_high

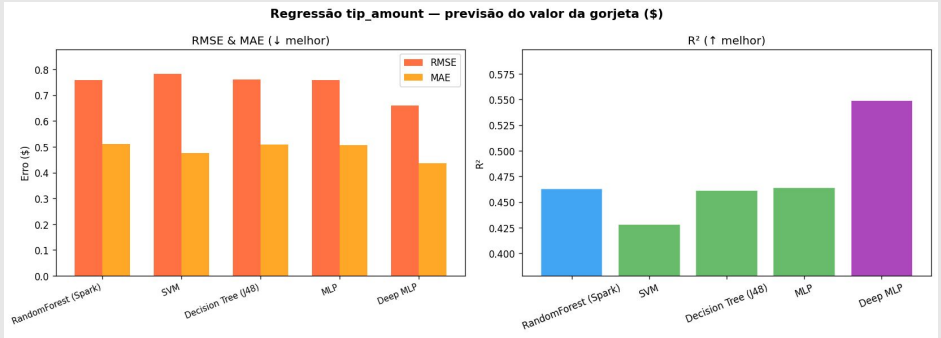
Os gráficos abaixo comparam o desempenho de todos os modelos na tarefa de classificação nominal ***tip_high***, avaliando **Accuracy, F1-score, AUC-ROC** e o conjunto completo de métricas por modelo.

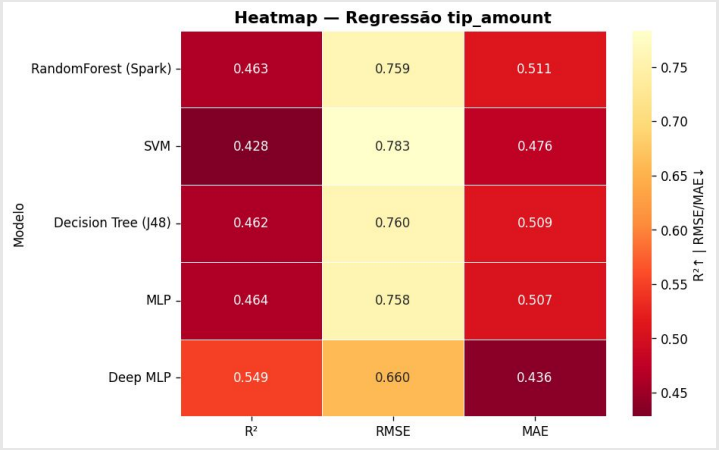




Comparação - tip_amount

Os gráficos abaixo comparam o desempenho de todos os modelos na tarefa de regressão numérica ***tip_amount***, com base nas métricas **R², RMSE e MAE.**

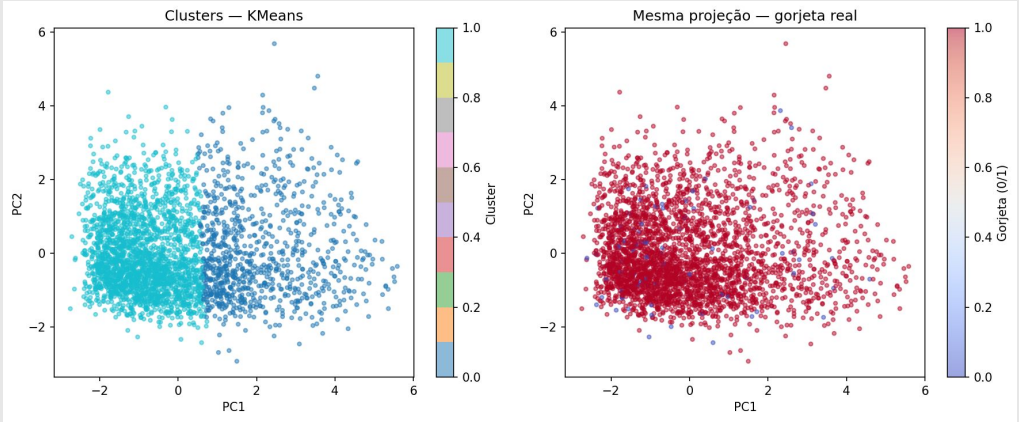




Clusters - KMeans

O KMeans (k=2) agrupa viagens apenas pelas features da viagem (**tarifa, distância, duração, hora, passageiros, etc.**) – sem usar a gorjeta no treino.
O Cluster 0 corresponde a viagens tipicamente mais **curtas e baratas** e o Cluster 1 a viagens mais **longas e dispendiosas.**

O gráfico da direita colore a mesma projeção pela gorjeta real (tip_given): **quase todos os pontos são vermelhos (com gorjeta) em ambos os clusters**. Os grupos refletem perfil da viagem, não padrão de gorjeta.
A gorjeta **não é bem capturável por clustering não supervisionado nestas features** – motivo para usar modelos supervisionados (tip_high, regressão).

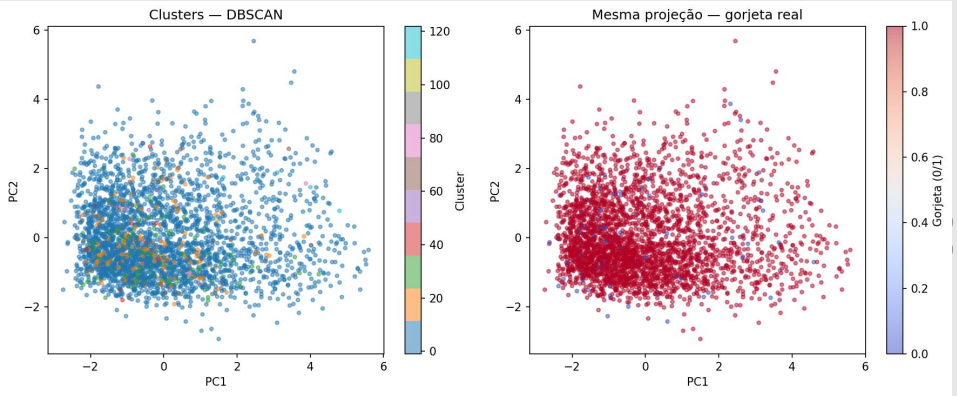


Clusters - DBSCAN

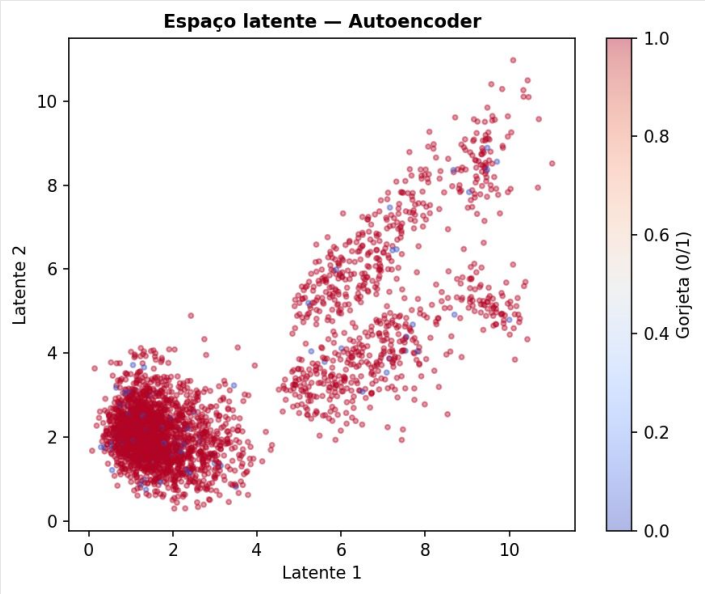
O algoritmo **agrupa viagens muito próximas no espaço das features** (tarifa, distância, duração, hora, etc.) e marca como ruído (~4%) as que não pertencem a nenhum grupo denso.

Ao contrário do KMeans (k=2), o DBSCAN descobriu **124 grupos automaticamente**, revelando **muitos micro-padrões de viagem**.

Tal como no K-Means, o **DBSCAN não apresenta uma separação clara das observações com base na gorjeta**. Apesar de identificar um cluster principal e vários micro-clusters, estes **não** correspondem a diferentes padrões de gratificação, indicando que o **comportamento de gorjeta não é capturado** por métodos de agrupamento não supervisionado.



Resultados Autoencoder



O espaço latente mostra um **cluster denso** de viagens normais e uma **dispersão diagonal** de viagens progressivamente mais atípicas.

Os pontos sem gorjeta espalham-se ao longo de toda a dispersão diagonal:

As anomalias têm **diversas origens** (tarifas incomuns, distâncias atípicas, combinações raras), **não apenas ausência de gorjeta.**

Modelo	Accuracy	Precision	Recall	F1-score	AUC-ROC
Naive Bayes	0.9664	0.9665	0.9999	0.9829	0.5576
Random Forest	0.7087	0.9407	0.7087	0.8019	0.5823
Decision Tree (J48)	0.6425	0.9712	0.6494	0.7783	0.5621

GaussianNB – NaiveBayes

```
=== Summary ===

Correctly Classified Instances      554408               96.2783 %
Incorrectly Classified Instances     21431                3.7217 %
Kappa statistic                          0.0106
Mean absolute error                      0.0688
Root mean squared error                  0.1867
Relative absolute error                103.1844 %
Root relative squared error            102.2283 %
Total Number of Instances           575839

=== Detailed Accuracy By Class ===

               TP Rate  FP Rate  Precision  Recall   F-Measure  MCC      ROC Area  PRC Area  Class
               0,009    0,003    0,095      0,009    0,017      0,019    0,688     0,063     0
               0,997    0,991    0,966      0,997    0,981      0,019    0,688     0,985     1
Weighted Avg.  0,963    0,957    0,936      0,963    0,948      0,019    0,688     0,953

=== Confusion Matrix ===

      a      b   <-- classified as
    180  19714 |      a = 0
   1717 554228 |      b = 1
```

RF – RF

```
=== Summary ===

Correctly Classified Instances      555336               96.4395 %
Incorrectly Classified Instances     20503                3.5605 %
Kappa statistic                          0.0054
Mean absolute error                      0.0655
Root mean squared error                  0.1863
Relative absolute error                 98.1411 %
Root relative squared error            101.9913 %
Total Number of Instances           575839

=== Detailed Accuracy By Class ===

               TP Rate  FP Rate  Precision  Recall   F-Measure  MCC      ROC Area  PRC Area  Class
               0,004    0,001    0,106      0,004    0,008      0,014    0,691     0,068     0
               0,999    0,996    0,966      0,999    0,982      0,014    0,691     0,982     1
Weighted Avg.  0,964    0,962    0,936      0,964    0,948      0,014    0,691     0,950

=== Confusion Matrix ===

      a      b   <-- classified as
     82  19812 |      a = 0
    691 555254 |      b = 1
```

Decision Tree – J48

```
=== Summary ===

Correctly Classified Instances      555943               96.5449 %
Incorrectly Classified Instances     19896                3.4551 %
Kappa statistic                         -0
Mean absolute error                      0.0666
Root mean squared error                  0.1825
Relative absolute error                 99.8982 %
Root relative squared error             99.9434 %
Total Number of Instances           575839

=== Detailed Accuracy By Class ===

               TP Rate  FP Rate  Precision  Recall   F-Measure  MCC      ROC Area  PRC Area  Class
               0,000    0,000    0,000      0,000    0,000      -0,000   0,524     0,037     0
               1,000    1,000    0,965      1,000    0,982      -0,000   0,524     0,968     1
Weighted Avg.  0,965    0,965    0,932      0,965    0,948      -0,000   0,524     0,935

=== Confusion Matrix ===

      a      b   <-- classified as
      0  19894 |      a = 0
      2 555943 |      b = 1
```

Modelo	Accuracy	Precision	Recall	F1-score	AUC-ROC
MLP (Perceptron)	0.6566	0.9716	0.6641	0.7889	0.5775
SVM	0.6436	0.9713	0.6504	0.7791	0.5680
Logistic Regression	0.6024	0.9397	0.6024	0.7243	0.5554

MLP – MLP

```
=== Summary ===

Correctly Classified Instances      555945               96.5452 %
Incorrectly Classified Instances     19894                3.4548 %
Kappa statistic                          0
Mean absolute error                      0.063
Root mean squared error                  0.1799
Relative absolute error                 94.4835 %
Root relative squared error             98.4951 %
Total Number of Instances           575839

=== Detailed Accuracy By Class ===

               TP Rate  FP Rate  Precision  Recall   F-Measure  MCC      ROC Area  PRC Area  Class
               0,000    0,000    ?          0,000    ?          ?        0,724     0,095     0
               1,000    1,000    0,965      1,000    0,982      ?        0,724     0,987     1
Weighted Avg.  0,965    0,965    ?          0,965    ?          ?        0,724     0,956

=== Confusion Matrix ===

      a      b   <-- classified as
      0  19894 |      a = 0
      0 555945 |      b = 1
```

SVM – SMO

```
=== Summary ===

Correctly Classified Instances      555945               96.5452 %
Incorrectly Classified Instances     19894                3.4548 %
Kappa statistic                          0
Mean absolute error                      0.0345
Root mean squared error                  0.1859
Relative absolute error                 51.7879 %
Root relative squared error            101.7735 %
Total Number of Instances           575839

=== Detailed Accuracy By Class ===

               TP Rate  FP Rate  Precision  Recall   F-Measure  MCC      ROC Area  PRC Area  Class
               0,000    0,000    ?          0,000    ?          ?        0,500     0,035     0
               1,000    1,000    0,965      1,000    0,982      ?        0,500     0,965     1
Weighted Avg.  0,965    0,965    ?          0,965    ?          ?        0,500     0,933

=== Confusion Matrix ===

      a      b   <-- classified as
      0  19894 |      a = 0
      0 555945 |      b = 1
```

LogisticRegression – funcLogistic

```
=== Summary ===

Correctly Classified Instances      555944               96.545  %
Incorrectly Classified Instances     19895                3.455  %
Kappa statistic                          0.0005
Mean absolute error                      0.065
Root mean squared error                  0.1802
Relative absolute error                 97.4062 %
Root relative squared error             98.6414 %
Total Number of Instances           575839

=== Detailed Accuracy By Class ===

               TP Rate  FP Rate  Precision  Recall   F-Measure  MCC      ROC Area  PRC Area  Class
               0,000    0,000    0,455      0,000    0,001      0,010    0,707     0,091     0
               1,000    1,000    0,965      1,000    0,982      0,010    0,707     0,986     1
Weighted Avg.  0,965    0,965    0,948      0,965    0,948      0,010    0,707     0,955

=== Confusion Matrix ===

      a      b   <-- classified as
      5  19889 |      a = 0
      6 555939 |      b = 1
```

Conclusão

Concluímos que a escolha dos **targets** e das **features** é decisiva – tip_given é muito desbalanceado; **tip_high e tip_amount** são mais adequadas.

Métodos não supervisionados **não substituem** modelos supervisionados para prever gorjetas.
O **desbalanceamento de um dataset** levará, evidentemente, a **análises desbalanceadas**.

Não existe um modelo universalmente superior:

- **Spark ML/Random Forest para classificação**: melhor F1-score e AUC-ROC.
- **Deep MLP para regressão**: maior R^2 e menor RMSE e MAE.

